

Predicción de Alzas Significativas en el Mercado Bursátil con Machine Learning y Explicabilidad mediante LLM

XGBoost + SHAP + Groq (Llama-3.1) para señales de trading interpretables

Camilo Álvarez Villegas

calvarezv1@eafit.edu.co

Matías Monsalve Ruiz

mmonsalvr1@eafit.edu.co

Samuel Calderón Duque

sscalderod@eafit.edu.co

Escuela de Ciencias Aplicadas e Ingeniería . Universidad EAFIT

Curso: Inteligencia Artificial . Semestre 2026-1

Entrega: 21 de mayo de 2026

Repositorio: https://github.com/CSM-Coders/Proyecto_Final_IA

Resumen

Contexto: La predicción de movimientos bursátiles a corto plazo es un problema desafiante por la eficiencia informacional de los mercados financieros. **Objetivo:** Construir un sistema que prediga alzas diarias superiores al 0.5 % en 10 acciones del S&P 500 y genere explicaciones en lenguaje natural comprensibles para inversionistas no técnicos. **Método:** Pipeline de indicadores técnicos (17 features), comparación de Logistic Regression, Random Forest y XGBoost con tuning Optuna (60 trials), explicabilidad con SHAP, y generación de reportes narrativos vía Groq API (Llama-3.1-8b) con few-shot prompting. **Resultados:** AUC-ROC = 0.576 (RF, mejor modelo), superando el baseline (LR, AUC = 0.524) en +5.2 puntos porcentuales. El componente LLM logró 100% de coherencia en la señal y referenció en promedio 1.7 de 3 factores clave. **Conclusión:** El sistema demuestra capacidad predictiva modesta pero consistente, alineada con la hipótesis de eficiencia de mercado, y valida el uso de LLMs para hacer la IA explicable en finanzas.

Palabras clave: Machine Learning, XGBoost, SHAP, LLM, Explicabilidad, Mercados Financieros.

1. Introducción

La predicción de movimientos bursátiles ha sido un tema central en finanzas cuantitativas desde que Fama [1] propuso la hipótesis de eficiencia del mercado (EMH). Según la EMH en su forma débil, los precios históricos ya reflejan toda la información disponible, lo que limita la capacidad predictiva de modelos basados exclusivamente en datos de precio y volumen. Sin embargo, avances recientes en machine learning han mostrado que modelos no lineales pueden capturar patrones sutiles que los

modelos lineales tradicionales no detectan [2].

Un desafío adicional es la **explicabilidad**: incluso cuando un modelo tiene capacidad predictiva, los inversionistas necesitan entender *por qué* el modelo sugiere una acción particular. Lundberg y Lee [3] propusieron SHAP como método para descomponer predicciones individuales en contribuciones por feature, pero los valores SHAP siguen siendo técnicos para un usuario final.

Este proyecto aborda ambos problemas con la siguiente **pregunta de investigación**:

“¿Puede un modelo de machine learning predecir alzas diarias superiores al 0.5 % en acciones del S&P 500 con AUC-ROC superior a 0.55, y puede un LLM generar explicaciones coherentes de esas predicciones usando valores SHAP como contexto?”

El sistema combina un pipeline de ML clásico (Bloque 2) con un componente de IA generativa (Bloque 3) que traduce los factores SHAP a lenguaje natural. El dataset proviene de Yahoo Finance (10 tickers, 5 años, 12,370 observaciones). El resto del documento presenta el EDA (Sección 2), la arquitectura (Sección 3), la metodología (Sección 4), los resultados (Sección 5), la discusión (Sección 6) y las conclusiones (Sección 7).

2. Datos y Exploración (EDA)

2.1. Descripción del dataset

Cuadro 1: Resumen del dataset utilizado

Atributo	Descripción
Fuente	Yahoo Finance vía yfinance API
Activos	AAPL, MSFT, GOOG, NFLX, AMZN, JPM, V, WMT, KO, JNJ
Registros (N)	12,370 filas (tras feature engineering)
Features (p)	17 numéricas + 10 dummies de ticker
Variable objetivo	Alza >0.5 % al día siguiente (binaria)
Periodo	Enero 2020 – Diciembre 2024
Balance	36.5 % positivos / 63.5 % negativos

2.2. Hallazgos del análisis exploratorio

El EDA reveló cuatro hallazgos principales que guiaron las decisiones de modelado:

Desbalance moderado del target. Solo el 36.5 % de los días presentan alzas superiores al 0.5 %, como muestra la Figura 1. Este desbalance motivó el uso de `class_weight="balanced"` en los modelos y la calibración del umbral de decisión.

Correlación entre sectores. La matriz de correlación de retornos (Figura 2) muestra que AAPL-MSFT tienen correlación de 0.75, mientras que pares inter-sectoriales (NFLX-KO: 0.14) son mucho más bajos. Esto justifica incluir múltiples sectores para diversificar la información del modelo.

Outliers como eventos reales. Se detectaron 84 outliers ($|z| > 4$, 0.67 % del total), concentrados en marzo 2020 (COVID) y periodos de alta volatilidad. No se eliminaron porque representan eventos de mercado reales cuya predicción es valiosa.

Valores nulos. El dataset de yfinance no contiene valores nulos. Los únicos NaN surgen de las ventanas rolling iniciales (primeras 20 sesiones para MA20), eliminados con `dropna()` como parte del pipeline.




Figura 1: Distribución de la variable objetivo: 63.5 % de los días no presentan alza significativa (>0.5 %).




Figura 2: Distribución de retornos diarios (izq.) y matriz de correlación de Pearson entre los 10 activos (der.).

3. Arquitectura del Sistema

El sistema sigue un pipeline secuencial de tres etapas: (1) ingesta y feature engineering, (2) modelado y evaluación ML, y (3) explicabilidad con SHAP + LLM. La Figura 3 muestra la arquitectura general.




Figura 3: Arquitectura del sistema: datos → features → ML → SHAP → LLM → reporte.

3.1. Componentes principales

Preprocesamiento. Pipeline de 17 indicadores técnicos calculados a partir de precio y volumen: medias móviles (MA5, MA10, MA20), cruces de medias, RSI-14, MACD con señal e histograma, ancho de bandas de Bollinger, volatilidad rolling 20d, retornos rezagados (1d, 5d, 20d), volumen relativo y estocástico-K. División temporal: train (hasta 2023-06) / val (hasta 2024-03) / test (2024-04 en adelante). Escalamiento con `StandardScaler` ajustado exclusivamente en train.

Modelo de ML. Tres modelos comparados: Logistic Regression (baseline), Random Forest (500 árboles, profundidad 8) y XGBoost con hiperparámetros optimizados por Optuna (60 trials). Todos usan `class_weight` o `scale_pos_weight` para manejar el desbalance.

Componente LLM. Groq API con llama-3.1-8b-instant (gratuito). Estrategia: few-shot prompting con un ejemplo que demuestra el formato y tono deseado. El LLM recibe los top-5 valores SHAP de cada predicción y genera un reporte de 4-5 oraciones en español, indicando la señal (ALCISTA/BAJISTA), confianza, factores principales y riesgos. Los prompts están documentados en el notebook.

4. Metodología

4.1. Configuración experimental

Cuadro 2: Hiperparámetros del mejor modelo (XGBoost vía Optuna)

Parámetro	Valor
n_estimators	325 (rango buscado: 200-800)
max_depth	3
learning_rate	0.049
subsample	0.622
colsample_bytree	0.658
reg_alpha	0.064
reg_lambda	2.854
Métrica de optimización	AUC-ROC
Framework	scikit-learn + XGBoost
Hardware	Google Colab (CPU)

4.2. Estrategia de validación

Se utilizó **hold-out temporal**: train (70 %), validación (15 %) y test (15 %), con cortes por fecha para respetar la naturaleza secuencial de los datos financieros. Este esquema evita data leakage temporal, a diferencia de k-fold aleatorio que mezcla pasado y futuro. El scaler se ajustó solo en train y se aplicó a val/test por separado.

4.3. Experimentos realizados

- 1. **Baseline:** Logistic Regression con `class_weight="balanced"` y `max_iter=500`. Establece el piso de rendimiento.
- 2. **Experimento 1 (RF):** Random Forest con 500 árboles, profundidad máxima 8, balanceo de clases. Sin tuning adicional.

- 3. **Experimento 2 (XGBoost):** XGBClassifier con 60 trials de Optuna optimizando AUC-ROC en validación. Mejor modelo por AUC en val (0.577).

5. Resultados

5.1. Métricas de evaluación

Cuadro 3: Comparación de modelos – métricas en test set (n=1,900)

Modelo	Acc.	F1	AUC	MCC
Baseline (LR)	0.636	0.120	0.524	0.047
Exp. 1 (RF)	0.621	0.305	0.576	0.086
Exp. 2 (XGBoost)	0.644	0.032	0.570	0.052

La Tabla 3 muestra que Random Forest logra el mejor AUC-ROC (0.576), superando al baseline en +5.2 puntos porcentuales. XGBoost obtiene AUC similar (0.570) pero con F1 bajo debido a un umbral de decisión conservador. La mejora sobre azar (AUC = 0.50) es consistente y estadísticamente significativa dado el tamaño del test set (n=1,900).

5.2. Curvas de entrenamiento




Figura 4: Curvas de AUC-ROC en train y validación para XGBoost. La brecha indica overfitting moderado controlado por la regularización (reg_lambda=2.85).

La Figura 4 muestra que el AUC de validación se estabiliza alrededor de 0.58 después de 100 iteraciones, mientras que el de train sigue subiendo. La brecha indica overfitting moderado, esperable en datos financieros ruidosos, pero controlado por la alta regularización seleccionada por Optuna.

5.3. Análisis por ticker




Figura 5: Relación entre volatilidad y predicibilidad por ticker. JPM (finanzas) es el más predecible (AUC=0.613).

La Figura 5 revela que 8 de 10 tickers tienen AUC superior a 0.50. JPM destaca con AUC=0.613, lo cual puede deberse a que las acciones financieras responden más a indicadores técnicos que las tecnológicas. AAPL (0.49) y KO (0.49) están cercanas al azar, sugiriendo alta eficiencia informativa.

5.4. Explicabilidad y LLM




Figura 6: SHAP beeswarm: vol_20d (volatilidad rolling) es la feature más influyente, seguida de RSI-14 y MA5.

El análisis SHAP (Figura 6) muestra que la volatilidad de 20 días es el factor más importante globalmente, se-

guido del RSI-14 y la media móvil de 5 días. Las features de distancia normalizada al precio (dist_ma20) generan valores SHAP extremos en casos puntuales.

La evaluación cuantitativa del LLM sobre 15 predicciones diversas arrojó: coherencia de señal ALCISTA/BAJISTA en el 100 % de los casos, mención promedio de 1.7 de 3 factores clave, y el 93 % de las respuestas incluyen advertencias de riesgo. Un ejemplo:

```
1 # Input al LLM (generado automáticamente)
2 Ticker: JNJ | Prob: 0.29 | BAJISTA
3 SHAP top-5: vol_20d=-0.23, t_JNJ=-0.05,
4   ma5=-0.04, bb_width=-0.04, dist_ma20=-0.04
5
6 # Respuesta del LLM (Llama-3.1-8b v a Groq)
7 Se al: BAJISTA (confianza baja)
8 Johnson & Johnson muestra debilidad: el
9 volumen ha disminuido, el precio est por
10 debajo de su tendencia de mediano plazo.
11 Esto podr a indicar correccin a la baja.
```

Listing 1: Ejemplo de output del sistema para JNJ

6. Discusión

6.1. Interpretación de resultados

El AUC-ROC de 0.576 es modesto pero coherente con la literatura sobre predicción bursátil a corto plazo. Estudios recientes [4] reportan AUC entre 0.52 y 0.62 para predicción diaria usando indicadores técnicos, ubicando nuestro resultado en el rango esperado. El modelo supera al baseline en +5.2 pp, confirmando que los modelos no lineales capturan patrones que la regresión logística no detecta.

La pregunta de investigación se responde parcialmente: el modelo sí supera AUC = 0.55 a nivel agregado (0.576) y el LLM genera explicaciones coherentes en el 100 % de los casos evaluados. Sin embargo, no todos los tickers individualmente superan 0.55.

6.2. Limitaciones

- **Features limitadas a datos técnicos.** No se incluyeron datos fundamentales (earnings, ratios financieros) ni datos alternativos (sentimiento de noticias, redes sociales) que podrían mejorar la predicción.
- **Periodo de test limitado.** El test set cubre abril-diciembre 2024, un periodo particularmente alcista (bull market). La generalización a mercados bajistas no está verificada.
- **Evaluación del LLM semi-automática.** Los 15 casos de prueba se evaluaron con heurísticas de keywords, no con juicio humano experto. Una evaluación más rigurosa requeriría un panel de analistas financieros.
- **Costos de transacción no modelados.** La viabilidad económica de las señales no fue evaluada (spread, comisiones, slippage).

6.3. Trabajo futuro

- 1. **Incorporar datos alternativos.** Añadir sentimiento de noticias (vía API de NewsAPI o GDELT) y datos fundamentales como features adicionales. Estudios como [4] muestran que la fusión de datos técnicos y de sentimiento mejora el AUC en +3-8 pp.
- 2. **Agente de trading con LangGraph.** Extender el sistema a un agente ReAct que decida automáticamente entre consultar indicadores técnicos, buscar noticias recientes y generar el reporte, cerrando el ciclo de decisión.

7. Conclusiones

El sistema desarrollado demuestra que los modelos de ML no lineales (RF, XGBoost) capturan patrones predictivos en indicadores técnicos bursátiles que un modelo lineal no detecta, logrando AUC-ROC de 0.576 frente a 0.524 del baseline. Este resultado es consistente con la hipótesis de eficiencia del mercado en su forma débil: la predicción es posible pero limitada.

El componente de explicabilidad vía SHAP + LLM (Llama-3.1-8b, Groq API) genera reportes en lenguaje natural con 100 % de coherencia en la señal y 93 % de mención de riesgos, validando su utilidad como herramienta de comunicación entre el modelo y usuarios no técnicos.

La principal contribución es la integración end-to-end de ML clásico con IA generativa para explicabilidad financiera, un patrón replicable a otros dominios donde la interpretabilidad es crítica.

Contribuciones del equipo

Integrante	Contribución principal
Camilo	EDA, preprocesamiento, feature engineering
Matías	Modelado ML, tuning Optuna, evaluación
Samuel	SHAP, integración LLM (Groq), prompts
Los 3	Informe LaTeX, video demo, repositorio

Distribución de responsabilidades por integrante.

Repositorio y Demo

- **GitHub:** https://github.com/CSM-Coders/Proyecto_Final_IA
- **Video demo (≤3 min):** https://youtu.be/qY6_h1KhLoo
- **Instalación:** `pip install -r requirements.txt`

- **Notebook:** `notebooks/Stock_Market_IA_EAFIT.ipynb`

Referencias

[1] Fama, E. F. (1970). *Efficient Capital Markets: A Review of Theory and Empirical Work*. The Journal of Finance, 25(2), 383–417.

[2] Chen, T. & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System*. KDD 2016. <https://arxiv.org/abs/1603.02754>

[3] Lundberg, S. M. & Lee, S.-I. (2017). *A Unified Approach to Interpreting Model Predictions*. NeurIPS 2017. <https://arxiv.org/abs/1705.07874>

[4] Jiang, W. (2021). *Applications of deep learning in stock market prediction: Recent progress*. Expert Systems with Applications, 184, 115537.

[5] Groq, Inc. (2024). *Groq API Documentation*. <https://console.groq.com/docs>

[6] Aroussi, R. (2024). *yfinance: Download market data from Yahoo Finance API*. Repositorio GitHub. <https://github.com/ranaroussi/yfinance>

[7] Akiba, T., Sano, S., Yanase, T., Ohta, T. & Koyama, M. (2019). *Optuna: A Next-generation Hyperparameter Optimization Framework*. KDD 2019. <https://arxiv.org/abs/1907.10902>

A. Hiperparámetros explorados por Optuna

Optuna exploró 60 configuraciones con TPE sampler (seed=42). El espacio de búsqueda fue: `n_estimators` ∈ [200, 800], `max_depth` ∈ [3, 8], `learning_rate` ∈ [0, 0.1, 0.2] (log), `subsample` ∈ [0.6, 1.0], `colsample_bytree` ∈ [0.6, 1.0], `reg_alpha` ∈ [10⁻³, 1.0] (log), `reg_lambda` ∈ [0.5, 3.0], `scale_pos_weight` ∈ [0.8, 1.5]. El mejor trial (52) alcanzó AUC de validación = 0.577.

B. Evaluación cuantitativa del LLM

Se evaluaron 15 predicciones diversas del test set con tres criterios: (1) coherencia de la señal ALCISTA/BAJISTA con la probabilidad predicha, (2) mención de al menos 2 de los 3 factores SHAP principales, (3) inclusión de advertencias de riesgo. Resultados: 15/15 coherentes en señal (100 %), promedio 1.7/3 factores mencionados, 14/15 mencionan riesgos (93 %).